

Jorge Armando Castro Escudero

Cc. 98708993

Entrega 1

- **Contexto de aplicación**

En los últimos años se han reportado estudios sobre estabilización de suelos viales apoyados en la minería de datos y programas estadísticos para determinar relaciones estabilizantes/suelo que permitan obtener los mejores desempeños en el material a utilizarse en una estructura de pavimento. Algunos investigadores del área de suelos proponen minimizar el número de ensayos de laboratorio y crear estrategias de ubicación de muestreo mediante el desarrollo espacial de mapas de la resistencia a la compresión no confinada a diferentes niveles de tratamiento para cal y cemento, utilizando técnicas de aprendizaje automático y el uso de una base de datos compilada a partir de varios estudios sobre estabilización de suelos.

Para efectos del curso se seleccionó un challenge de www.kaggle.com llamado "soil types", para emplear las redes convulsionales e imágenes de diferentes tipos de suelos a modo de entrenamiento, en mi trabajo de tesis se emplearán datos propios.

- **Objetivo de machine learning**

En la clasificación de suelos a nivel de formación geológica existen varias categorías según su origen o color; para este ejercicio se consideran cinco categorías de la siguiente manera y con diferentes números de archivos.

Black soil: 37 imágenes, Cinder soil: 30 imágenes, Laterite soil: 30 imágenes, Peat soil: 30 imágenes, Yellow soil: 29 imágenes. Mediante el empleo de redes convulsionales, se desea predecir el tipo de suelo.

- **Dataset**

Para este ejercicio se emplean redes convulsionales, las imágenes fueron cargadas en el espacio de prueba del Colab, de acuerdo con una jerarquía de carpetas, luego se hace el cargue de las imágenes, se redimensionan y se etiquetan.

- Se importan las librerías de numpy y pandas para guardar en arreglos la información de cada tipo de imagen.
- Se utilizó tensorflow, el paquete de keras para redimensionar las imágenes
- Se reescalan las imágenes de 1/255 para manejar un RGB uniforme de las imágenes.
- Se subdividen los datos en: train y test

- Se hace el entrenamiento por medio de un batch de imágenes y se reagrupa de acuerdo con las categorías establecidas.

Black :0, Cinder: 1, Laterite:2, peat: 3, Yellow:4

- **Métricas de desempeño (de machine learning y negocio)**

- Se construye un modelo predictivo mediante la aplicación de una red neuronal convulsional de 128 neuronas y 5 salidas y mediante aplicación de las métricas "accuracy y epochs" se hará la evaluación del modelo para la predicción de datos futuros

- **Referencias y resultados previos**

Herramientas de Estadística para Toma de Decisiones: Minería de Datos e Inteligencia Artificial, GEN, Redes Neuronales

A continuación se hace referencia a algunos autores que han realizado trabajos en el área de estabilización de suelos empleando inteligencia artificial y redes neuronales. En el análisis de algunos suelos de Estados Unidos, se seleccionaron los mejores modelos para el tratamiento del cemento con el propósito de generar mapas espaciales para dos condados en Montana. Las muestras de suelo fueron probadas con diferentes contenidos de cemento para verificar las predicciones. Los resultados indican que en la correlación de Pearson el coeficiente para el modelo de regresión fue de 0,78 y el CPR para el modelo de clasificación fue del 92%. Se espera que el empleo de este tipo de estudios se convierta en una herramienta de toma de decisiones basada en datos en las prácticas de ingeniería geotécnica [1] Otro método empleado por El Dine Moustafa y colaboradores, son las redes neuronales artificiales ANNs, las cuales son una forma de inteligencia artificial que ha demostrado un alto nivel de competencia para resolver problemas complejos de ingeniería y que están más allá de la capacidad computacional de las matemáticas clásicas y procedimientos tradicionales. En particular, las ANNs se han aplicado con éxito a casi todos los aspectos de problemas y aplicaciones de la ingeniería geotécnica, siendo uno de ellos la estabilización de suelos mediante el uso de nanopartículas como aditivos para mejorar el desempeño del suelo. En este estudio se encontró que el uso de ANNs en la estabilización de suelos por nanotecnología ayuda a comprender el comportamiento de las mezclas suelo-nanomezclas, reduciendo además los costos del desarrollo de las formulaciones en laboratorio [2]. En el trabajo realizado por Gomes y Tinoco, se hace un enfoque de referencia a la eficiencia en la predicción de la resistencia a la compresión uniaxial (UCS); el módulo de Young elástico (E) de mezclas suelo-cemento es la expresión analítica propuesta en el Eurocódigo 2 para

la predicción de la resistencia y la rigidez del hormigón. Se demuestra cómo las técnicas de computación blanda, se pueden utilizar como una herramienta poderosa con fines predictivos de las propiedades mecánicas a lo largo del tiempo cuando se dispone de una base de datos histórica. Se presenta una propuesta novedosa para la predicción del módulo de diseño, basada en los resultados de ensayos de resistencia a la compresión uniaxiales convencionales. Este módulo es función del nivel de deformación del material estabilizado movilizado para el estado de servicio de la estructura [3]. Para examinar las propiedades de ingeniería de suelos estabilizados, tradicionalmente se emplean métodos que son laboriosos, lentos y costosos. Woubishet y Kassahun evaluaron cuatro modelos basados en inteligencia artificial para predecir el contenido de humedad óptimo, la densidad máxima seca y la resistencia a la compresión no confinada. Los modelos emplearon siete características que describen la proporción y los tipos de suelos estabilizados, los límites de Atterberg y los grupos de clasificación de suelos. Uno de los modelos empleó dos características adicionales que describen las propiedades de compactación. Los resultados fueron promisorios en la aplicación de los modelos desarrollados para predecir las propiedades evaluadas, encontrándose además que las propiedades de compactación juegan un papel importante en la predicción de la resistencia a la compresión no confinada. Se concluyó además que el rendimiento de todos los modelos podría mejorarse aún más con más datos y se pueden aplicar para determinar la dosificación óptima del estabilizante para satisfacer los requerimientos de la estabilización [4].

- [1].A. Gajurel, B. Chittoori, S. M. Partha y S. Mojtaba , «Machine learning methods to map stabilizer effectiveness based on common soil properties,» *Transportation Geotechnics*, vol. 27, 2021
- [2] H. K. El Dine Moustafa, H. A., A. Hesham Kamal y K. Elzahabby, «Study for Application of Artificial Neural Networks in Soil,» de *Seventh International Conference on Nanotechnology in Construction*, El Cairo, 2015.
- [3]A. Gomes Correia y J. Tinoco, «Advanced tools and techniques to add value to soil stabilization practice,» *Innovative Infrastructure Solutions*, vol. 2, nº 26, 2017.
- [4] W. Taffese y K. Admassu Abegaz, «Artificial Intelligence for Prediction of Physical and Mechanical Properties of Stabilized Soil for Affordable Housing,» *Applied Science*, vol. 11, nº 16, p. 7503, 2021.